



Совместная программа СМОЛ
ГУ и ФКН НИУ ВШЭ

2026/27 учебный год

Методы оптимизации в машинном обучении

Лекция 1. Оптимизация как язык машинного
обучения

Никита Лукьяненко



О преподавателе

- Никита Лукьяненко
- старший преподаватель ФКН НИУ ВШЭ
- преподавательский опыт: теория вероятностей, математическая статистика, статистическая теория обучения
- интересы курса: математическая сторона обучения моделей и вычислительное поведение алгоритмов

Как будем работать

Моя цель — не перечислить как можно больше методов, а научить вас понимать, **что именно оптимизируется, почему алгоритм устроен так и когда он может работать плохо.**





Что будет в курсе

Пять вопросов, к которым мы будем возвращаться весь год

Как формализовать задачу обучения?



Как устроена геометрия целевой функции?



Как найти минимум?



Почему алгоритм сходится и насколько быстро?




Что меняется в больших задачах машинного обучения?

Главный герой первого семестра — градиентный спуск.



Как устроен курс



На лекциях

Определения, геометрическая интуиция, ключевые утверждения и небольшое число доказательств.

На практике

Сначала маленькие задачи, где алгоритм можно увидеть целиком; затем — модели и реальные данные.

В течение семестра: 4 домашние лабораторные работы.



Система оценивания

Активность	Обозначение	Вес
Домашние задания / 4 лабораторные работы	<i>H</i>	0.20
Контрольная работа	<i>C</i>	0.25
Коллоквиум	<i>K</i>	0.25
Экзамен	<i>E</i>	0.50

Каждая активность оценивается целым числом от 0 до 10.

Расчёт

$$S = 0.20H + 0.25C + 0.25K + 0.50E.$$

Итоговая оценка получается арифметическим округлением рассчитанного результата.

Ориентировочные сроки: контрольная работа — первая половина ноября; коллоквиум — вторая половина ноября.

Домашние работы: 4 лабораторные работы в течение семестра; точные дедлайны объявляются заранее.



Начнём с самой простой задачи

Рассмотрим функцию

$$f(x) = (x - 3)^2 + 1.$$

Вопрос

Какое значение x нужно выбрать, чтобы сделать $f(x)$ как можно меньше?



Начнём с самой простой задачи


Рассмотрим функцию

$$f(x) = (x - 3)^2 + 1.$$

Вопрос

Какое значение x нужно выбрать, чтобы сделать $f(x)$ как можно меньше?

$$x^* = 3, \quad f(x^*) = 1.$$





Общая задача оптимизации

Что означает запись?

$$\min_{x \in X} f(x)$$

Нужно выбрать **допустимое** значение $x \in X$, при котором значение $f(x)$ как можно меньше.

X

что выбираем
переменная оптимизации

$f(x)$

что минимизируем
целевая функция

X

где можем выбирать
допустимое множество

Типичная интерпретация в машинном обучении

x — параметры модели, $f(x)$ — мера ошибки модели.



Минимум и минимизатор — разные объекты

Минимизатор

Точка (или множество точек), где достигается наименьшее значение:

$$x^* \in \arg \min_x f(x).$$

Для $f(x) = (x - 3)^2 + 1$:

$$\arg \min_x f(x) = \{3\}, \quad \min_x f(x) = 1.$$

$\arg \min$ = **где?**

$\min$ = **сколько?**

Минимальное значение

Число — значение функции в оптимальной точке:

$$f^* = \min_x f(x).$$




Минимизатор может быть не единственным

$$f(x) = (x^2 - 1)^2.$$

$$\arg \min_x f(x) = \{-1, 1\}.$$

Важно

$\arg \min$ в общем случае —
МНОЖЕСТВО, а не одна точка.





А минимум вообще всегда существует?

$$f(x) = x^2$$

Минимум существует:

$$\min f = 0.$$

$$x^* = 0$$

$$f(x) = e^x$$

$$\inf f = 0,$$

но $e^x > 0$ при любом
конечном x .

Минимума нет.

$$f(x) = -x^2$$

$$f(x) \rightarrow -\infty$$

при $|x| \rightarrow \infty$.

Функция не ограничена
снизу.

Три фундаментальных вопроса курса

Существует ли решение? Единственно ли оно? Как его найти?



Добавление константы не меняет минимизаторы

Теорема

Пусть $g(x) = f(x) + C$, где C не зависит от x . Тогда

$$\arg \min_x g(x) = \arg \min_x f(x).$$



Добавление константы не меняет минимизаторы

Теорема

Пусть $g(x) = f(x) + C$, где C не зависит от x . Тогда

$$\arg \min_x g(x) = \arg \min_x f(x).$$

Доказательство.

Для любых x_1, x_2 :

$$f(x_1) \leq f(x_2) \iff f(x_1) + C \leq f(x_2) + C.$$

Следовательно, добавление C не меняет порядок значений функции и не меняет точки, в которых значение минимально. □



Положительное масштабирование тоже не меняет минимизаторы

Теорема

Если $g(x) = Cf(x)$ и $C > 0$, то

$$\arg \min_x g(x) = \arg \min_x f(x).$$



Положительное масштабирование тоже не меняет минимизаторы

Теорема

Если $g(x) = Cf(x)$ и $C > 0$, то

$$\arg \min_x g(x) = \arg \min_x f(x).$$

Поскольку при $C > 0$

$$f(x_1) \leq f(x_2) \iff Cf(x_1) \leq Cf(x_2).$$

А если $C < 0$?

$$\arg \min_x Cf(x) = \arg \max_x f(x).$$

Отрицательное масштабирование переворачивает порядок.



Почему это понадобится в машинном обучении

Если $\ell_i(w)$ — ошибка модели на объекте i , то часто встречаются две записи:

$$F_1(w) = \sum_{i=1}^n \ell_i(w), \quad F_2(w) = \frac{1}{n} \sum_{i=1}^n \ell_i(w).$$

Поскольку $1/n > 0$,

$$\arg \min_w F_1(w) = \arg \min_w F_2(w).$$

То есть

Для положения минимума сумма и среднее эквивалентны. Но их производные и численные масштабы отличаются — позже это станет важным для выбора шага алгоритма.



Не все преобразования безобидны

Исходная задача

Рассмотрим $x \in [-1, 1]$ и

$$f(x) = x.$$

Тогда

$$\arg \min_{x \in [-1, 1]} f(x) = \{-1\}.$$

Вывод

Даже простое преобразование целевой функции может изменить решение задачи оптимизации.

После преобразования

Возведём целевую функцию в квадрат:

$$g(x) = f(x)^2 = x^2.$$

Теперь

$$\arg \min_{x \in [-1, 1]} g(x) = \{0\}.$$



Небольшая задача

Пусть

$$f(x) = (x - 2)^2.$$

Найдите минимизаторы следующих функций:

$$f(x),$$

$$3f(x),$$

$$f(x) + 100,$$

$$-f(x).$$

На обсуждение: 2 минуты.



Что делает модель машинного обучения?

Пусть есть обучающая выборка

$$(x_i, y_i), \quad i = 1, \dots, n.$$

Модель с параметрами w строит предсказание

$$\hat{y}_i = h_w(x_i).$$

Что мы можем менять?

Данные x_i, y_i уже зафиксированы. Во время обучения мы подбираем **параметры модели** w .

обучение = выбор хорошего значения w



Функция потерь: насколько плохо одно предсказание?

Определение

Функция потерь $\ell(\hat{y}, y)$ сопоставляет предсказанию и правильному ответу число, измеряющее ошибку.


Для регрессии естественный пример:

$$\ell(\hat{y}, y) = (\hat{y} - y)^2.$$

Если $\hat{y} = y$, то

$$\ell = 0.$$

Чем дальше предсказание от ответа, тем больше штраф.





От одного объекта ко всей выборке

Ошибка на объекте i :

$$\ell_i(w) = \ell(h_w(x_i), y_i).$$

Средняя ошибка на обучающей выборке:

$$F(w) = \frac{1}{n} \sum_{i=1}^n \ell_i(w)$$

называется **эмпирическим риском**.



От одного объекта ко всей выборке

Ошибка на объекте i :

$$\ell_i(w) = \ell(h_w(x_i), y_i).$$

Средняя ошибка на обучающей выборке:

$$F(w) = \frac{1}{n} \sum_{i=1}^n \ell_i(w)$$


называется **эмпирическим риском**.

Обучение модели превращается в задачу

$$w^* \in \arg \min_w F(w)$$



Универсальная схема обучения



$$\min_w F(w)$$

Где начинается наш курс

Архитектура модели и выбор функции потерь задают F . Дальше возникает вопрос: **как эффективно минимизировать эту функцию по параметрам w ?**



Разные модели — одна оптимизационная структура

Линейная регрессия

$$\hat{y} = w^T x + b$$

$$\min_{w,b} F(w, b)$$

Логистическая
регрессия

$$p = \sigma(w^T x + b)$$

$$\min_{w,b} F(w, b)$$

Нейронная сеть

$$\hat{y} = h_w(x)$$

$$\min_w F(w)$$

Меняются модель и функция потерь, но остаётся вопрос

как найти хорошие параметры?



Пример 1: линейная регрессия

В одномерном случае модель имеет вид


$$\hat{y} = wx + b.$$

Нужно подобрать два параметра:

w и b .

Интерпретация

w отвечает за наклон прямой, b — за вертикальный сдвиг.





Среднеквадратичная ошибка

Для наблюдений (x_i, y_i) и модели $\hat{y}_i = wx_i + b$ определим

$$F(w, b) = \frac{1}{n} \sum_{i=1}^n (wx_i + b - y_i)^2.$$

Тогда обучение линейной регрессии — это

$$\min_{w, b} \frac{1}{n} \sum_{i=1}^n (wx_i + b - y_i)^2$$

Переменные оптимизации

w, b

Целевая функция

$F(w, b)$

Сегодня мы только ставим задачу. Градиент этой функции появится позже.



Два пространства, которые важно не путать

Пространство данных

Каждая пара (w, b) задаёт прямую

$$y = wx + b.$$

Мы видим, насколько хорошо она проходит через наблюдения.

Пространство параметров

Каждой паре (w, b) соответствует число

$$F(w, b).$$

Оптимизация происходит именно здесь:

$$(w, b) \mapsto F(w, b).$$

Ключевая мысль

Модель живёт в пространстве данных, а алгоритм оптимизации двигается в пространстве параметров.



Пример 2: бинарная классификация

Пусть

$$y \in \{0, 1\}.$$

Линейное выражение $w^\top x + b$ может принимать любые вещественные значения, поэтому само по себе не является вероятностью.

Используем логистическую функцию:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

$$p(y = 1 \mid x) = \sigma(w^\top x + b).$$

$$\sigma(z) \in (0, 1) \text{ для любого } z \in \mathbb{R}.$$



Логистическая функция потерь

Обозначим

$$p_i = \sigma(w^\top x_i + b).$$

Одна из стандартных функций потерь для бинарной классификации:

$$F(w, b) = -\frac{1}{n} \sum_{i=1}^n \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right].$$

И снова обучение имеет вид

$$\min_{w, b} F(w, b).$$

Пока принимаем формулу как данность

Её вывод из принципа максимального правдоподобия не нужен для сегодняшней цели. Нам важно увидеть оптимизационную структуру.



Всегда ли нужно минимизировать только ошибку?

Представьте две модели:

- первая почти идеально подстраивается под обучающие данные, но очень сложна;
- вторая ошибается немного сильнее, зато устроена заметно проще.

В машинном обучении часто нужен **компромисс** между качеством подгонки и сложностью модели.

Идея регуляризации

Добавим к ошибке штраф за нежелательные значения параметров.



Регуляризованная задача

$$\min_w \left[\underbrace{\frac{1}{n} \sum_{i=1}^n \ell_i(w)}_{\text{ошибка на данных}} + \lambda \underbrace{R(w)}_{\text{штраф}} \right]$$

w

параметры модели

то, что мы подбираем

$R(w)$

регуляризатор

штраф за
нежелательные
параметры

$\lambda \geq 0$

сила штрафа

задаёт баланс двух
частей

Пример: $R(w) = \|w\|_2^2$.

Чем больше λ , тем сильнее целевая функция штрафует большие значения параметров.



Оптимизация как компромисс

$$\underbrace{\text{ошибка на данных}}_{\text{хочется уменьшить}} + \lambda \underbrace{\text{сложность модели}}_{\text{хочется контролировать}}$$

Важно

Оптимизация не обязательно означает «минимизировать ошибку любой ценой». Мы сначала **конструируем целевую функцию**, которая отражает нужный нам компромисс, а уже потом ищем её минимум.



Вся первая лекция — в одной формуле

$$w^* \in \arg \min_w \left[\frac{1}{n} \sum_{i=1}^n \ell(h_w(x_i), y_i) + \lambda R(w) \right]$$

- w — параметры модели;
- h_w — модель;
- ℓ — ошибка на одном объекте;
- R — регуляризатор;
- λ — сила регуляризации.



Но как найти w^* ?

Если параметров два, поверхность функции можно хотя бы нарисовать.

А если параметров — миллион?

Следующий вопрос курса

Как использовать геометрию функции, чтобы понять, **куда двигаться из текущей точки?**

Следующая лекция: **линейная алгебра для оптимизации.**



Что нужно унести с собой

1. Задача оптимизации имеет вид $\min_{x \in X} f(x)$.
2. $\arg \min$ обозначает точки-минимизаторы, $\min$ — минимальное значение.
3. Обучение модели часто сводится к минимизации среднего значения функции потерь.
4. Регуляризация добавляет в целевую функцию штраф и меняет компромисс, который мы оптимизируем.
5. Следующая задача — научиться находить минимум алгоритмически.

К следующему занятию: повторить векторы, матрицы, скалярное произведение и собственные значения.