



Совместная программа СМОЛ  
ГУ и ФКН НИУ ВШЭ

2026/27 учебный год

# Методы оптимизации в машинном обучении

Лекция 1. Оптимизация как язык машинного  
обучения

Никита Лукьяненко



## О преподавателе

- Никита Лукьяненко
- старший преподаватель ФКН НИУ ВШЭ
- преподавательский опыт: теория вероятностей, математическая статистика, статистическая теория обучения
- интересы курса: математическая сторона обучения моделей и вычислительное поведение алгоритмов



### Как будем работать

Моя цель — не перечислить как можно больше методов, а научить вас понимать, **что именно оптимизируется, почему алгоритм устроен так и когда он может работать плохо.**



# Что будет в курсе

Пять вопросов, к которым мы будем возвращаться весь год

Как формализовать задачу обучения?



Как устроена геометрия целевой функции?



Как найти минимум?



Почему алгоритм сходится и насколько быстро?




Что меняется в больших задачах машинного обучения?

**Главный герой первого семестра — градиентный спуск.**



# Как устроен курс



## На лекциях

Определения, геометрическая интуиция, ключевые утверждения и небольшое число доказательств.

## На практике

Сначала маленькие задачи, где алгоритм можно увидеть целиком; затем — модели и реальные данные.

**В течение семестра:** 4 домашние лабораторные работы.



## Система оценивания

| Активность                               | Обозначение | Вес  |
|------------------------------------------|-------------|------|
| Домашние задания / 4 лабораторные работы | <i>H</i>    | 0.20 |
| Контрольная работа                       | <i>C</i>    | 0.25 |
| Коллоквиум                               | <i>K</i>    | 0.25 |
| Экзамен                                  | <i>E</i>    | 0.50 |

Каждая активность оценивается целым числом от 0 до 10.

### Расчёт

$$S = 0.20H + 0.25C + 0.25K + 0.50E.$$

Итоговая оценка получается арифметическим округлением рассчитанного результата.

**Ориентировочные сроки:** контрольная работа — первая половина ноября; коллоквиум — вторая половина ноября.

**Домашние работы:** 4 лабораторные работы в течение семестра; точные дедлайны объявляются заранее.



## Начнём с самой простой задачи

Рассмотрим функцию

$$f(x) = (x - 3)^2 + 1.$$

### Вопрос

Какое значение  $x$  нужно выбрать, чтобы сделать  $f(x)$  как можно меньше?



## Начнём с самой простой задачи


Рассмотрим функцию

$$f(x) = (x - 3)^2 + 1.$$

### Вопрос

Какое значение  $x$  нужно выбрать, чтобы сделать  $f(x)$  как можно меньше?

$$x^* = 3, \quad f(x^*) = 1.$$





# Общая задача оптимизации

Что означает запись?

$$\min_{x \in X} f(x)$$

Нужно выбрать **допустимое** значение  $x \in X$ , при котором значение  $f(x)$  как можно меньше.

$X$

**что выбираем**  
переменная оптимизации

$f(x)$

**что минимизируем**  
целевая функция

$X$

**где можем выбирать**  
допустимое множество

Типичная интерпретация в машинном обучении

$x$  — параметры модели,       $f(x)$  — мера ошибки модели.



# Минимум и минимизатор — разные объекты

## Минимизатор

Точка (или множество точек), где достигается наименьшее значение:

$$x^* \in \arg \min_x f(x).$$

Для  $f(x) = (x - 3)^2 + 1$ :

$$\arg \min_x f(x) = \{3\}, \quad \min_x f(x) = 1.$$

$\arg \min$  = **где?**

$\min$  = **сколько?**

## Минимальное значение

Число — значение функции в оптимальной точке:

$$f^* = \min_x f(x).$$




# Минимизатор может быть не единственным

$$f(x) = (x^2 - 1)^2.$$

$$\arg \min_x f(x) = \{-1, 1\}.$$

**Важно**

$\arg \min$  в общем случае —  
**МНОЖЕСТВО**, а не одна точка.





# А минимум вообще всегда существует?

$$f(x) = x^2$$

Минимум существует:

$$\min f = 0.$$

$$x^* = 0$$

$$f(x) = e^x$$

$$\inf f = 0,$$

но  $e^x > 0$  при любом  
конечном  $x$ .

Минимума нет.

$$f(x) = -x^2$$

$$f(x) \rightarrow -\infty$$

при  $|x| \rightarrow \infty$ .

Функция не ограничена  
снизу.

## Три фундаментальных вопроса курса

Существует ли решение?   Единственно ли оно?   Как его найти?



## Добавление константы не меняет минимизаторы

### Теорема

*Пусть  $g(x) = f(x) + C$ , где  $C$  не зависит от  $x$ . Тогда*

$$\arg \min_x g(x) = \arg \min_x f(x).$$



## Добавление константы не меняет минимизаторы

### Теорема

Пусть  $g(x) = f(x) + C$ , где  $C$  не зависит от  $x$ . Тогда

$$\arg \min_x g(x) = \arg \min_x f(x).$$

### Доказательство.

Для любых  $x_1, x_2$ :

$$f(x_1) \leq f(x_2) \iff f(x_1) + C \leq f(x_2) + C.$$

Следовательно, добавление  $C$  не меняет порядок значений функции и не меняет точки, в которых значение минимально. □



# Положительное масштабирование тоже не меняет минимизаторы

## Теорема

Если  $g(x) = Cf(x)$  и  $C > 0$ , то

$$\arg \min_x g(x) = \arg \min_x f(x).$$



## Положительное масштабирование тоже не меняет минимизаторы

### Теорема

Если  $g(x) = Cf(x)$  и  $C > 0$ , то

$$\arg \min_x g(x) = \arg \min_x f(x).$$

Поскольку при  $C > 0$

$$f(x_1) \leq f(x_2) \iff Cf(x_1) \leq Cf(x_2).$$

А если  $C < 0$ ?

$$\arg \min_x Cf(x) = \arg \max_x f(x).$$

Отрицательное масштабирование переворачивает порядок.



## Почему это понадобится в машинном обучении

Если  $\ell_i(w)$  — ошибка модели на объекте  $i$ , то часто встречаются две записи:

$$F_1(w) = \sum_{i=1}^n \ell_i(w), \quad F_2(w) = \frac{1}{n} \sum_{i=1}^n \ell_i(w).$$

Поскольку  $1/n > 0$ ,

$$\arg \min_w F_1(w) = \arg \min_w F_2(w).$$

То есть

Для положения минимума сумма и среднее эквивалентны. Но их производные и численные масштабы отличаются — позже это станет важным для выбора шага алгоритма.



# Не все преобразования безобидны

## Исходная задача

Рассмотрим  $x \in [-1, 1]$  и

$$f(x) = x.$$

Тогда

$$\arg \min_{x \in [-1, 1]} f(x) = \{-1\}.$$

## Вывод

Даже простое преобразование целевой функции может изменить решение задачи оптимизации.

## После преобразования

Возведём целевую функцию в квадрат:

$$g(x) = f(x)^2 = x^2.$$

Теперь

$$\arg \min_{x \in [-1, 1]} g(x) = \{0\}.$$



## Небольшая задача

Пусть

$$f(x) = (x - 2)^2.$$

Найдите минимизаторы следующих функций:

$$f(x),$$

$$3f(x),$$

$$f(x) + 100,$$

$$-f(x).$$

**На обсуждение: 2 минуты.**



## Что делает модель машинного обучения?

Пусть есть обучающая выборка

$$(x_i, y_i), \quad i = 1, \dots, n.$$

Модель с параметрами  $w$  строит предсказание

$$\hat{y}_i = h_w(x_i).$$

Что мы можем менять?

Данные  $x_i, y_i$  уже зафиксированы. Во время обучения мы подбираем **параметры модели**  $w$ .

обучение = выбор хорошего значения  $w$



# Функция потерь: насколько плохо одно предсказание?

## Определение

Функция потерь  $\ell(\hat{y}, y)$  сопоставляет предсказанию и правильному ответу число, измеряющее ошибку.


Для регрессии естественный пример:

$$\ell(\hat{y}, y) = (\hat{y} - y)^2.$$

Если  $\hat{y} = y$ , то

$$\ell = 0.$$

Чем дальше предсказание от ответа, тем больше штраф.





## От одного объекта ко всей выборке

Ошибка на объекте  $i$ :

$$\ell_i(w) = \ell(h_w(x_i), y_i).$$

Средняя ошибка на обучающей выборке:

$$F(w) = \frac{1}{n} \sum_{i=1}^n \ell_i(w)$$

называется **эмпирическим риском**.



## От одного объекта ко всей выборке

Ошибка на объекте  $i$ :

$$\ell_i(w) = \ell(h_w(x_i), y_i).$$

Средняя ошибка на обучающей выборке:

$$F(w) = \frac{1}{n} \sum_{i=1}^n \ell_i(w)$$


называется **эмпирическим риском**.

Обучение модели превращается в задачу

$$w^* \in \arg \min_w F(w)$$



## Универсальная схема обучения



$$\min_w F(w)$$

Где начинается наш курс

Архитектура модели и выбор функции потерь задают  $F$ . Дальше возникает вопрос: **как эффективно минимизировать эту функцию по параметрам  $w$ ?**



# Разные модели — одна оптимизационная структура

Линейная регрессия

$$\hat{y} = w^T x + b$$

$$\min_{w,b} F(w, b)$$

Логистическая  
регрессия

$$p = \sigma(w^T x + b)$$

$$\min_{w,b} F(w, b)$$

Нейронная сеть

$$\hat{y} = h_w(x)$$

$$\min_w F(w)$$

Меняются модель и функция потерь, но остаётся вопрос

как найти хорошие параметры?



## Пример 1: линейная регрессия

В одномерном случае модель имеет вид


$$\hat{y} = wx + b.$$

Нужно подобрать два параметра:

$w$  и  $b$ .

### Интерпретация

$w$  отвечает за наклон прямой,  $b$  — за вертикальный сдвиг.





## Среднеквадратичная ошибка

Для наблюдений  $(x_i, y_i)$  и модели  $\hat{y}_i = wx_i + b$  определим

$$F(w, b) = \frac{1}{n} \sum_{i=1}^n (wx_i + b - y_i)^2.$$

Тогда обучение линейной регрессии — это

$$\min_{w, b} \frac{1}{n} \sum_{i=1}^n (wx_i + b - y_i)^2$$

Переменные оптимизации

$w, b$

Целевая функция

$F(w, b)$

**Сегодня мы только ставим задачу. Градиент этой функции появится позже.**



## Два пространства, которые важно не путать

### Пространство данных

Каждая пара  $(w, b)$  задаёт прямую

$$y = wx + b.$$

Мы видим, насколько хорошо она проходит через наблюдения.

### Пространство параметров

Каждой паре  $(w, b)$  соответствует число

$$F(w, b).$$

Оптимизация происходит именно здесь:

$$(w, b) \mapsto F(w, b).$$

### Ключевая мысль

Модель живёт в пространстве данных, а алгоритм оптимизации двигается в пространстве параметров.



## Пример 2: бинарная классификация

Пусть

$$y \in \{0, 1\}.$$

Линейное выражение  $w^\top x + b$  может принимать любые вещественные значения, поэтому само по себе не является вероятностью.

Используем логистическую функцию:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

$$p(y = 1 \mid x) = \sigma(w^\top x + b).$$

$$\sigma(z) \in (0, 1) \text{ для любого } z \in \mathbb{R}.$$



# Логистическая функция потерь

Обозначим

$$p_i = \sigma(w^\top x_i + b).$$

Одна из стандартных функций потерь для бинарной классификации:

$$F(w, b) = -\frac{1}{n} \sum_{i=1}^n \left[ y_i \log p_i + (1 - y_i) \log(1 - p_i) \right].$$

И снова обучение имеет вид

$$\min_{w, b} F(w, b).$$

Пока принимаем формулу как данность

Её вывод из принципа максимального правдоподобия не нужен для сегодняшней цели. Нам важно увидеть оптимизационную структуру.



# Всегда ли нужно минимизировать только ошибку?

Представьте две модели:

- первая почти идеально подстраивается под обучающие данные, но очень сложна;
- вторая ошибается немного сильнее, зато устроена заметно проще.

В машинном обучении часто нужен **компромисс** между качеством подгонки и сложностью модели.

Идея регуляризации

Добавим к ошибке штраф за нежелательные значения параметров.



## Регуляризованная задача

$$\min_w \left[ \underbrace{\frac{1}{n} \sum_{i=1}^n \ell_i(w)}_{\text{ошибка на данных}} + \lambda \underbrace{R(w)}_{\text{штраф}} \right]$$

$w$

**параметры модели**

то, что мы подбираем

$R(w)$

**регуляризатор**

штраф за  
нежелательные  
параметры

$\lambda \geq 0$

**сила штрафа**

задаёт баланс двух  
частей

**Пример:**  $R(w) = \|w\|_2^2$ .

Чем больше  $\lambda$ , тем сильнее целевая функция штрафует большие значения параметров.



## Оптимизация как компромисс

$$\underbrace{\text{ошибка на данных}}_{\text{хочется уменьшить}} + \lambda \underbrace{\text{сложность модели}}_{\text{хочется контролировать}}$$

### Важно

Оптимизация не обязательно означает «минимизировать ошибку любой ценой». Мы сначала **конструируем целевую функцию**, которая отражает нужный нам компромисс, а уже потом ищем её минимум.



## Вся первая лекция — в одной формуле

$$w^* \in \arg \min_w \left[ \frac{1}{n} \sum_{i=1}^n \ell(h_w(x_i), y_i) + \lambda R(w) \right]$$

- $w$  — параметры модели;
- $h_w$  — модель;
- $\ell$  — ошибка на одном объекте;
- $R$  — регуляризатор;
- $\lambda$  — сила регуляризации.



Но как найти  $w^*$ ?

Если параметров два, поверхность функции можно хотя бы нарисовать.

А если параметров — миллион?

Следующий вопрос курса

Как использовать геометрию функции, чтобы понять, **куда двигаться из текущей точки?**

Следующая лекция: **линейная алгебра для оптимизации.**



## Что нужно унести с собой

1. Задача оптимизации имеет вид  $\min_{x \in X} f(x)$ .
2.  $\arg \min$  обозначает точки-минимизаторы,  $\min$  — минимальное значение.
3. Обучение модели часто сводится к минимизации среднего значения функции потерь.
4. Регуляризация добавляет в целевую функцию штраф и меняет компромисс, который мы оптимизируем.
5. Следующая задача — научиться находить минимум алгоритмически.

**К следующему занятию: повторить векторы, матрицы, скалярное произведение и собственные значения.**