



Совместная программа СМОЛ ГУ и
ФКН НИУ ВШЭ

2026/27 учебный год

Методы оптимизации в машинном обучении

Лекция 3. Квадратичная оптимизация: геометрия, спектр и
точное решение

Никита Лукьяненко



От локальной геометрии — к точному классу задач

На прошлой лекции мы получили локальную квадратичную модель

$$f(x + h) \approx f(x) + \nabla f(x)^\top h + \frac{1}{2} h^\top \nabla^2 f(x) h.$$

Первый порядок

$$\nabla f(x)$$

описывает локальный наклон.

Второй порядок

$$\nabla^2 f(x)$$

описывает локальную кривизну.

Сегодня рассмотрим класс функций, для которых квадратичная модель описывает функцию **точно**.



Когда квадратичное приближение становится точным?


Для общей гладкой функции формула второго порядка лишь приближает поведение около выбранной точки.

Для квадратичной функции остатка нет:

$$f(x + h) = f(x) + \nabla f(x)^\top h + \frac{1}{2} h^\top \nabla^2 f(x) h.$$

Почему это удобно?

Мы можем полностью понять геометрию задачи, а затем использовать её как модель для более общих функций.





Почему квадратичные задачи важны?

1. Их можно исследовать полностью

Условия существования и единственности решения выражаются через спектр одной матрицы.

2. Они описывают локальную геометрию

Около точки минимума гладкая функция во втором порядке выглядит квадратично.


3. Они возникают непосредственно в машинном обучении

Метод наименьших квадратов — классический пример квадратичной оптимизации.




Одна формула — очень разная геометрия


круглая чаша



вытянутая чаша



седло



Главный вопрос лекции

Как по матрице квадратичной функции заранее понять, какая геометрия перед нами?



Квадратичная функция

Определение

Функция

$$f(x) = \frac{1}{2}x^{\top}Ax - b^{\top}x + c, \quad x \in \mathbb{R}^d$$

называется квадратичной, где

$$A \in \mathbb{R}^{d \times d}, \quad b \in \mathbb{R}^d, \quad c \in \mathbb{R}.$$

Матрица A будет отвечать за кривизну и форму поверхности; b — за положение её центра; c — за вертикальный сдвиг.



Что делает каждый член?


$$f(x) = \frac{1}{2}x^\top Ax - b^\top x + c.$$

- A задаёт **форму**;
- b сдвигает оптимум;
- c не меняет оптимум вообще.


Важно

Изменяя b и c , мы не меняем гессиан квадратичной функции.


только A: форма



добавили b: сдвиг минимума



добавили c: вертикальный сдвиг





Зачем перед квадратичной формой ставят $1/2$?

Множитель $1/2$ не меняет сути задачи. Он выбран ради удобства производных.

В одном измерении:

$$\frac{d}{dx} \left(\frac{1}{2} ax^2 \right) = ax.$$

В нескольких измерениях при симметричной A аналогично:

$$\nabla \left(\frac{1}{2} x^\top Ax \right) = Ax.$$

Соглашение

В оптимизации запись $\frac{1}{2} x^\top Ax$ используется очень часто именно потому, что она убирает лишнюю двойку из градиента.



Обязательно ли считать A симметричной?

Любую квадратную матрицу можно разложить как

$$A = \underbrace{\frac{A + A^T}{2}}_S + \underbrace{\frac{A - A^T}{2}}_K,$$

где

$$S^T = S, \quad K^T = -K.$$

Вопрос

Может ли кососимметричная часть K влиять на величину $x^T A x$?

На следующем слайде ответим на этот вопрос формально.



Кососимметричная часть не влияет на квадратичную форму

Утверждение

Если $K^T = -K$, то для любого $x \in \mathbb{R}^d$

$$x^T K x = 0.$$

Доказательство

Величина $x^T K x$ — число, поэтому она совпадает со своим транспонированием:

$$x^T K x = (x^T K x)^T = x^T K^T x.$$

Но $K^T = -K$, следовательно,

$$x^T K x = -x^T K x.$$

Значит,

$$2x^T K x = 0,$$

что и требовалось доказать.



Поэтому можно считать A симметричной

Из разложения $A = S + K$ и предыдущего утверждения получаем

$$x^T Ax = x^T Sx + x^T Kx = x^T Sx.$$

Следовательно,

$$x^T Ax = x^T \frac{A + A^T}{2} x.$$

Вывод

Для квадратичной оптимизации несимметричная часть матрицы не видна вообще. Поэтому дальше без ограничения общности считаем

$$A = A^T.$$



Пример в $\mathbb{R}^2$


Пусть

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 4 \end{pmatrix}, \quad b = \begin{pmatrix} 1 \\ 2 \end{pmatrix}.$$

Тогда при $c = 0$

$$\begin{aligned} f(x_1, x_2) &= \frac{1}{2}x^\top Ax - b^\top x \\ &= x_1^2 + x_1x_2 + 2x_2^2 - x_1 - 2x_2. \end{aligned}$$

Линии уровня уже дают важную информацию о форме задачи.





Самопроверка: восстановите матричную запись

Рассмотрим

$$f(x, y) = 3x^2 - 2xy + y^2 + 4x - 6y + 7.$$

Представьте её в форме

$$f(z) = \frac{1}{2}z^{\top}Az - b^{\top}z + c, \quad z = \begin{pmatrix} x \\ y \end{pmatrix}.$$

Вопросы

Каковы A , b и c ? Почему коэффициент перед xy нужно особенно внимательно сопоставлять с матрицей?

На обсуждение: около минуты.



Градиент квадратичной формы

Утверждение

Пусть $A = A^T$. Тогда

$$\nabla \left(\frac{1}{2} x^T A x \right) = Ax.$$

Это многомерный аналог знакомой формулы

$$\frac{d}{dx} \left(\frac{1}{2} ax^2 \right) = ax.$$

Почему доказательство полезно?

Оно показывает, как аккуратно работать с индексами и где именно используется симметрия A .



Доказательство формулы для градиента

Запишем

$$\frac{1}{2}x^\top Ax = \frac{1}{2} \sum_{i=1}^d \sum_{j=1}^d A_{ij} x_i x_j.$$

Для k -й координаты градиента

$$\frac{\partial}{\partial x_k} \left(\frac{1}{2} x^\top Ax \right) = \frac{1}{2} \sum_{j=1}^d A_{kj} x_j + \frac{1}{2} \sum_{i=1}^d A_{ik} x_i.$$

Так как $A_{ik} = A_{ki}$,

$$\frac{\partial}{\partial x_k} \left(\frac{1}{2} x^\top Ax \right) = \sum_{j=1}^d A_{kj} x_j = (Ax)_k.$$

Это верно для всех k , поэтому

$$\boxed{\nabla \left(\frac{1}{2} x^\top Ax \right) = Ax.}$$



Линейный и постоянный члены

Для линейного члена

$$b^T x = \sum_{i=1}^d b_i x_i,$$

поэтому

$$\nabla(b^T x) = b.$$

Следовательно,

$$\nabla(-b^T x) = -b.$$

А постоянный член не зависит от x :

$$\nabla c = 0.$$

Итого

Для квадратичной функции остаётся только сложить три простых результата.



Главная формула: градиент квадратичной функции

Для

$$f(x) = \frac{1}{2}x^{\top}Ax - b^{\top}x + c, \quad A = A^{\top},$$

получаем

$$\nabla f(x) = Ax - b.$$

Обратите внимание

Градиент линейно зависит от текущей точки x . Это сделает анализ градиентного спуска на следующей лекции почти полностью алгебраическим.



Гессиан ещё проще

Поскольку

$$\nabla f(x) = Ax - b,$$

ещё одно дифференцирование даёт

$$\nabla^2 f(x) = A.$$

Ключевая особенность

Гессиан квадратичной функции не зависит от точки x . Кривизна поверхности одинакова везде.



У общей функции кривизна меняется, у квадратичной — нет

В одном измерении кривизну отражает вторая производная.


Для общей функции:

$f''(x)$ зависит от x .

Для квадратичной:

$q''(x) = \text{const.}$

В многомерном случае роль второй производной играет матрица $\nabla^2 f(x)$.





Кривизна вдоль направления

С прошлой лекции мы знаем: для единичного направления v

$$\left. \frac{d^2}{dt^2} f(x + tv) \right|_{t=0} = v^\top \nabla^2 f(x) v.$$

Для квадратичной функции

$$\kappa(v) = v^\top A v.$$

Что особенно удобно

Эта величина зависит от направления v , но **не зависит от точки x** .

Теперь вопрос о геометрии функции превращается в вопрос о квадратичной форме $v^\top A v$.



Начнём с диагональной матрицы

Пусть

$$A = \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix}.$$

Тогда

$$f(x) = \frac{1}{2} x^\top A x = \frac{1}{2} (\lambda_1 x_1^2 + \lambda_2 x_2^2).$$

Преимущество диагонального случая

Координаты не взаимодействуют: вклад каждого направления виден отдельно.

Именно к такой форме мы сведём произвольную симметричную матрицу с помощью собственных векторов.



Если собственные значения одинаковы

При

$$A = I$$

имеем

$$f(x) = \frac{1}{2}(x_1^2 + x_2^2).$$


Линия уровня $f(x) = C$ задаётся условием

$$x_1^2 + x_2^2 = 2C,$$

то есть является окружностью.

Геометрия

Кривизна одинакова во всех направлениях.





Если собственные значения различаются

Для

$$A = \begin{pmatrix} 1 & 0 \\ 0 & 10 \end{pmatrix}$$


получаем

$$f(x) = \frac{1}{2}(x_1^2 + 10x_2^2).$$

Линии уровня становятся эллипсами.

Интуиция

В направлении x_2 функция растёт значительно быстрее, поэтому допустимое отклонение по этой координате меньше.





Что означает большое собственное значение?

Если v_i — собственный вектор с собственным значением λ_i , то


$$Av_i = \lambda_i v_i.$$

Рассмотрим движение только вдоль этого направления: $x = tv_i$. Для $\|v_i\| = 1$

$$f(tv_i) = \frac{1}{2} t^2 v_i^\top A v_i = \frac{1}{2} \lambda_i t^2.$$

Вывод

Чем больше λ_i , тем сильнее функция изгибается и быстрее растёт вдоль направления v_i .





Недиагональная матрица просто поворачивает главные оси

Например,

$$A = \begin{pmatrix} 5 & 4 \\ 4 & 5 \end{pmatrix}.$$


Линии уровня по-прежнему эллипсы, но их оси уже не совпадают с координатными осями.

Новый вопрос

Как найти естественные направления, вдоль которых квадратичная функция снова выглядит как сумма независимых квадратов?

Ответ — собственные векторы A .

Главные оси эллипса = собственные направления





Спектральная теорема для симметричной матрицы

Теорема

Если $A = A^T$, то существует ортогональная матрица Q и диагональная матрица Λ , такие что

$$A = Q\Lambda Q^T,$$

где столбцы Q — ортонормированные собственные векторы A , а

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_d).$$

На этой лекции

Спектральную теорему используем без доказательства. Нас интересуют её последствия для оптимизации.



Переходим в собственные координаты

Положим

$$z = Q^T x, \quad \text{то есть} \quad x = Qz.$$

Тогда

$$x^T A x = z^T Q^T (Q \Lambda Q^T) Q z = z^T \Lambda z.$$

Следовательно,

$$x^T A x = \sum_{i=1}^d \lambda_i z_i^2.$$

Смысл

После поворота координат любая симметричная квадратичная форма становится суммой независимых одномерных квадратичных функций.



Почему преобразование действительно является только поворотом?

Матрица Q ортогональна:

$$Q^T Q = I.$$

Поэтому она сохраняет длины:

$$\|Qz\|^2 = z^T Q^T Q z = \|z\|^2.$$

И сохраняет скалярные произведения:

$$(Qz_1)^T (Qz_2) = z_1^T z_2.$$

Геометрическая интерпретация

Переход $x = Qz$ не растягивает пространство. Он лишь меняет ортонормированный базис так, чтобы его оси совпали с собственными направлениями A .




Как из собственных значений увидеть форму линии уровня?

В собственных координатах возьмём

$$f(z) = \frac{1}{2} (z_1^2 + 6z_2^2), \quad \lambda_1 = 1, \quad \lambda_2 = 6.$$

На линии уровня $f(z) = 1$

$$z_1^2 + 6z_2^2 = 2, \quad a_1 = \sqrt{\frac{2}{\lambda_1}} = \sqrt{2}, \quad a_2 = \sqrt{\frac{2}{\lambda_2}} = \sqrt{\frac{1}{3}}.$$



Вывод: большее λ_i означает более сильную кривизну вдоль v_i и более короткую полуось линии уровня.



Спектральные границы квадратичной формы

Утверждение

Для симметричной A и любого $x \in \mathbb{R}^d$

$$\lambda_{\min}(A) \|x\|^2 \leq x^T A x \leq \lambda_{\max}(A) \|x\|^2.$$

Доказательство

В собственных координатах $z = Q^T x$:

$$x^T A x = \sum_i \lambda_i z_i^2.$$

Так как $\lambda_{\min} \leq \lambda_i \leq \lambda_{\max}$,

$$\lambda_{\min} \sum_i z_i^2 \leq \sum_i \lambda_i z_i^2 \leq \lambda_{\max} \sum_i z_i^2.$$

Ортогональность Q даёт $\|z\| = \|x\|$.



Положительная определённость

Определение

Симметричная матрица A называется **положительно определённой**, если

$$x^T A x > 0 \quad \text{для любого } x \neq 0.$$

Обозначение:

$$A \succ 0.$$

Если допускается равенство нулю,

$$x^T A x \geq 0 \quad \forall x,$$

то A называется положительно полуопределённой и пишут

$$A \succeq 0.$$



Как проверить $A \succ 0$, не перебирая все направления?

Определение требует проверять знак $x^T A x$ для бесконечного множества векторов x . Для симметричной матрицы спектр превращает эту проверку в конечную.

Спектральный критерий

Для симметричной матрицы A

$$A \succ 0 \iff \lambda_{\min}(A) > 0.$$

То есть достаточно посмотреть на **наименьшее** собственное значение.

- $\lambda_{\min} > 0$ — положительно определённая чаша;
- $\lambda_{\min} = 0$ и отрицательных значений нет — есть плоские направления;
- $\lambda_{\min} < 0$ — существует направление отрицательной кривизны.

Следующий слайд — доказательство критерия.



Доказательство спектрального критерия

Пусть сначала все $\lambda_i > 0$. В собственных координатах

$$x^T A x = \sum_i \lambda_i z_i^2.$$

Если $x \neq 0$, то и $z \neq 0$, поэтому хотя бы одно $z_i \neq 0$, а значит

$$x^T A x > 0.$$

Следовательно, $A \succ 0$.

Теперь пусть $A \succ 0$. Возьмём собственный вектор $v_i \neq 0$:

$$A v_i = \lambda_i v_i.$$

Тогда

$$v_i^T A v_i = \lambda_i \|v_i\|^2.$$

Левая часть положительна, а $\|v_i\|^2 > 0$. Поэтому $\lambda_i > 0$.

$$A \succ 0 \iff \lambda_i > 0 \forall i.$$



$A \succ 0$: единственная чашеобразная геометрия

Для

$$f(x) = \frac{1}{2}x^T A x, \quad A \succ 0,$$

имеем

$$f(x) > 0 \quad \text{при } x \neq 0, \quad f(0) = 0.$$

Поэтому


$$x^* = 0$$

— единственный глобальный минимум.

Геометрия

Во всех направлениях кривизна положительна: поверхность изгибается вверх.

$A \succ 0$: единственная чаша





Отрицательное собственное значение разрушает ограниченность снизу

Пусть у A есть собственный вектор v с

$$Av = \lambda v, \quad \lambda < 0.$$

Рассмотрим точки $x = tv$. Тогда

$$f(tv) = \frac{1}{2}t^2 v^\top Av = \frac{1}{2}\lambda t^2 \|v\|^2.$$

Так как $\lambda < 0$,

$$f(tv) \longrightarrow -\infty \quad \text{при } |t| \rightarrow \infty.$$

Вывод

Если у квадратичной части есть отрицательное собственное значение, то чистая квадратичная функция $\frac{1}{2}x^\top Ax$ не ограничена снизу.



Собственные значения разных знаков: седловая геометрия

Если существуют

$$\lambda_i > 0, \quad \lambda_j < 0,$$


то в одном собственном направлении функция растёт вверх, а в другом — вниз.

Следствие

Точка $x = 0$ стационарна для $\frac{1}{2}x^T Ax$, но не является ни минимумом, ни максимумом.

Такую точку называют седловой.

Собственные значения разных знаков: седло





Полуопределённость: минимум может быть не единственным

Пусть

$$A = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}.$$

Тогда

$$f(x_1, x_2) = \frac{1}{2}x_1^2.$$


Минимальное значение равно нулю для всех точек

$$x_1 = 0.$$

Важно

Нулевое собственное значение означает направление с нулевой кривизной. В этом направлении поверхность плоская.

$A \geq 0$: минимум вдоль целой прямой





Но при $A \succeq 0$ линейный член может всё изменить

Рассмотрим

$$f(x, y) = x^2 - y.$$

Её гессиан

$$\nabla^2 f = \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix} \succeq 0.$$

Но при $y \rightarrow +\infty$

$$f(x, y) \rightarrow -\infty.$$

Вывод

Положительная полуопределённость квадратичной части сама по себе ещё не гарантирует существование минимума, если присутствует линейный член.

Общий полуопределённый случай пока оставим за рамками курса. Для основной теории сосредоточимся на $A \succ 0$.



Ищем минимум при $A \succ 0$

Для

$$f(x) = \frac{1}{2}x^\top Ax - b^\top x + c$$

имеем

$$\nabla f(x) = Ax - b.$$

В точке внутреннего минимума необходимо

$$\nabla f(x^*) = 0.$$

Следовательно,

$$\boxed{Ax^* = b.}$$

То есть задача минимизации свелась к решению системы линейных уравнений.



Точное решение

Если $A \succ 0$, то A обратима. Поэтому из

$$Ax^* = b$$

следует

$$x^* = A^{-1}b.$$

Но есть важный практический нюанс

В вычислениях почти никогда не стоит явно находить A^{-1} . Обычно решают систему

$$Ax = b$$

специализированным численным методом.

Формула $A^{-1}b$ важна для теории, но не обязательно является хорошим алгоритмом.



Почему положительно определённая матрица обратима?

Утверждение

Если $A \succ 0$, то A невырождена.

Доказательство

Предположим, что

$$Ax = 0.$$

Тогда

$$x^T Ax = x^T 0 = 0.$$

Но положительная определённость требует

$$x^T Ax > 0$$

для любого $x \neq 0$. Значит, равенство $Ax = 0$ возможно только при $x = 0$.

Следовательно,

$$\ker A = \{0\},$$

а значит A обратима.



Теорема о минимуме квадратичной функции

Теорема

Пусть

$$f(x) = \frac{1}{2}x^{\top}Ax - b^{\top}x + c, \quad A = A^{\top} \succ 0.$$

Тогда f имеет единственный глобальный минимум, причём

$$x^* = A^{-1}b.$$

Почему это сильнее условия $\nabla f = 0$?

Условие первого порядка само по себе говорит лишь о стационарности. Положительная определённость позволяет доказать и глобальность, и единственность минимума.



Доказательство: дополняем до квадрата

Пусть $x^* = A^{-1}b$, то есть $b = Ax^*$. Рассмотрим разность

$$f(x) - f(x^*).$$

Подставляя $b = Ax^*$ и используя симметрию A , получаем

$$\begin{aligned} f(x) - f(x^*) &= \frac{1}{2}x^\top Ax - (x^*)^\top Ax + \frac{1}{2}(x^*)^\top Ax^* \\ &= \frac{1}{2}(x - x^*)^\top A(x - x^*). \end{aligned}$$

Так как $A \succ 0$,

$$(x - x^*)^\top A(x - x^*) > 0 \quad \text{для } x \neq x^*.$$

Следовательно,

$$f(x) > f(x^*) \quad \forall x \neq x^*.$$

Значит, x^* — единственный глобальный минимум.



Линейный член сдвигает минимум, но не меняет форму

При фиксированной $A \succ 0$

$$\nabla^2 f(x) = A$$

не зависит от b .



Но положение минимума

$$x^* = A^{-1}b$$

зависит от b .

Геометрически

b передвигает центр эллиптической чаши, не меняя её главные направления и кривизну.





Связь с линейной регрессией

В курсе машинного обучения вы уже работаете с задачей наименьших квадратов. Здесь посмотрим только на её **оптимизационную структуру**.

Пусть

$$X \in \mathbb{R}^{n \times d}, \quad y \in \mathbb{R}^n,$$

а предсказания имеют вид Xw .

Среднеквадратичная задача:

$$\min_w \frac{1}{2} \|Xw - y\|^2.$$

Это квадратичная оптимизация по параметрам w .



Разворачиваем квадрат нормы

Используем

$$\|Xw - y\|^2 = (Xw - y)^\top (Xw - y).$$

Тогда

$$\begin{aligned} f(w) &= \frac{1}{2} (Xw - y)^\top (Xw - y) \\ &= \frac{1}{2} w^\top X^\top Xw - y^\top Xw + \frac{1}{2} y^\top y. \end{aligned}$$

Сравним с общей формой

$$\frac{1}{2} w^\top Aw - b^\top w + c.$$



Матрица квадратичной задачи для линейной регрессии

Из предыдущего разложения:

$$A = X^T X,$$

$$b = X^T y,$$

$$c = \frac{1}{2} y^T y.$$

Следовательно,

$$\nabla f(w) = X^T (Xw - y),$$

$$\nabla^2 f(w) = X^T X.$$

Оптимизационная геометрия линейной регрессии

Она полностью определяется спектром матрицы $X^T X$.



Почему $X^T X$ всегда положительно полуопределена?

Утверждение

Для любой матрицы X

$$X^T X \succeq 0.$$

Доказательство

Для любого $z \in \mathbb{R}^d$

$$z^T X^T X z = (Xz)^T (Xz) = \|Xz\|^2 \geq 0.$$

Следовательно, по определению

$$X^T X \succeq 0.$$

Это объясняет, почему функция наименьших квадратов никогда не имеет седловой квадратичной геометрии.



Когда решение линейной регрессии единственно?

Для $X^T X$ положительная определённость означает

$$z^T X^T X z = \|Xz\|^2 > 0 \quad \forall z \neq 0.$$

Это эквивалентно условию

$$Xz \neq 0 \quad \forall z \neq 0,$$

то есть

$$\ker X = \{0\}.$$

Иными словами

Если столбцы X линейно независимы, то $X^T X \succ 0$ и решение единственно.

Тогда условие $\nabla f(w) = 0$ даёт нормальные уравнения

$$X^T X w = X^T y.$$



Две задачи с одним минимумом могут быть очень разными

Рассмотрим

$$f_1(x) = \frac{1}{2}(x_1^2 + x_2^2),$$

$$f_2(x) = \frac{1}{2}(x_1^2 + 100x_2^2).$$

Обе функции:

- положительно определены;
- имеют единственный минимум в $x^* = 0$;
- имеют очень простую явную формулу.

Но кривизна по разным направлениям во второй задаче отличается в 100 раз. Нужна численная характеристика этой неоднородности.



Число обусловленности

Определение

Для симметричной положительно определённой матрицы A число

$$\kappa(A) = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}$$

называется спектральным числом обусловленности.

Так как $0 < \lambda_{\min} \leq \lambda_{\max}$,

$$\kappa(A) \geq 1.$$

Что именно измеряет κ ?

Не общую “крутизну” функции, а **неравномерность кривизны по разным направлениям**.

Действительно, для любого $c > 0$

$$\kappa(cA) = \frac{c\lambda_{\max}(A)}{c\lambda_{\min}(A)} = \kappa(A).$$



Число обусловленности — отношение экстремальных кривизн

Утверждение

Если $A = A^T \succ 0$, то

$$\max_{\|v\|=1} v^T A v = \lambda_{\max}(A), \quad \min_{\|v\|=1} v^T A v = \lambda_{\min}(A).$$

Следовательно,

$$\kappa(A) = \frac{\max_{\|v\|=1} v^T A v}{\min_{\|v\|=1} v^T A v}.$$

Доказательство

Из спектральных границ при $\|v\| = 1$:

$$\lambda_{\min} \leq v^T A v \leq \lambda_{\max}.$$

Обе границы достигаются на собственных векторах $v_{\min}$ и $v_{\max}$.



Число обусловленности точно задаёт вытянутость линии уровня

В собственных координатах

$$\frac{1}{2} \sum_i \lambda_i z_i^2 = c.$$




Полуось вдоль v_i равна

$$a_i = \sqrt{\frac{2c}{\lambda_i}}.$$

Поэтому

$$\frac{a_{\max}}{a_{\min}} = \sqrt{\frac{\lambda_{\max}}{\lambda_{\min}}} = \boxed{\sqrt{\kappa(A)}}.$$

Одна и та же линия уровня $\frac{1}{2}z^T \Lambda z = 1$



Точная геометрическая связь

Если $\kappa = 100$, то линия уровня вытянута по главным осям в $\sqrt{100} = 10$ раз.



Большая кривизна сама по себе не означает плохую обусловленность

Сравним две матрицы:

$$A_1 = I, \quad A_2 = 100I.$$

У второй функции кривизна во всех направлениях в 100 раз больше, но

$$\kappa(A_1) = 1, \quad \kappa(A_2) = \frac{100}{100} = 1.$$

Ключевой смысл

Хорошая обусловленность означает, что все главные направления имеют **сопоставимую** кривизну. Абсолютный масштаб собственных значений — другой вопрос.

Самопроверка

Что хуже обусловлено: $A = 0.01I$ или $A = \text{diag}(1, 100)$?



Почему это называется “обусловленностью”?

Число κ связано не только с формой линий уровня, но и с **чувствительностью решения** к небольшим изменениям задачи.

Пусть

$$x^* = A^{-1}b,$$

а после возмущения $b \mapsto b + \delta b$ решение изменилось на

$$x^* \mapsto x^* + \delta x.$$

Тогда

$$A \delta x = \delta b.$$

Оценка чувствительности

Для $b \neq 0$

$$\boxed{\frac{\|\delta x\|}{\|x^*\|} \leq \kappa(A) \frac{\|\delta b\|}{\|b\|} .}$$

То есть большое κ допускает сильное усиление относительной ошибки входных данных.



Откуда берётся оценка чувствительности?

Из $A\delta x = \delta b$ получаем

$$\delta x = A^{-1} \delta b.$$

Собственные значения A^{-1} равны $1/\lambda_i(A)$, поэтому

$$\|\delta x\| \leq \frac{1}{\lambda_{\min}(A)} \|\delta b\|.$$

С другой стороны,

$$\|b\| = \|Ax^*\| \leq \lambda_{\max}(A) \|x^*\|,$$

то есть

$$\frac{1}{\|x^*\|} \leq \frac{\lambda_{\max}(A)}{\|b\|}.$$

Перемножая оценки,

$$\frac{\|\delta x\|}{\|x^*\|} \leq \frac{\lambda_{\max}}{\lambda_{\min}} \frac{\|\delta b\|}{\|b\|} = \kappa(A) \frac{\|\delta b\|}{\|b\|}.$$



Одинаковое возмущение может по-разному сдвинуть минимум

Возьмём в обоих случаях

$$b = (0, 1)^T, \quad \delta b = (0.1, 0)^T.$$

Тогда относительное изменение b равно 10%.

- при $A = I$ имеем $\kappa = 1$ и относительный сдвиг решения 10%;
- при $A = \text{diag}(0.01, 1)$ имеем $\kappa = 100$ и относительный сдвиг решения 1000%.

Это пример, где оценка предыдущего слайда фактически достигается.





Почему обусловленность станет важна уже на следующей лекции



Градиент указывает локальное направление наискорейшего убывания:

$$-\nabla f(x).$$

Но при большом κ поверхность имеет очень разные кривизны по главным направлениям. Градиент оказывается сильно ориентирован поперёк узкой долины.

Вопрос

Как число обусловленности повлияет на допустимый шаг и скорость градиентного спуска?





$$f(x) = \frac{1}{2}x^\top Ax - b^\top x + c$$

$$\Downarrow$$

$$\nabla f(x) = Ax - b, \quad \nabla^2 f(x) = A$$

$$\Downarrow$$

$$A = Q\Lambda Q^\top$$

$$\Downarrow$$

$\lambda_i \iff$ кривизна по главным направлениям

$$\Downarrow$$

$$A \succ 0 \implies x^* = A^{-1}b, \quad \kappa(A) = \frac{\lambda_{\max}}{\lambda_{\min}}.$$



Следующая лекция: почему работает градиентный спуск?

Теперь для квадратичной функции мы точно знаем

$$\nabla f(x) = Ax - b.$$

Градиентный шаг имеет вид

$$x_{k+1} = x_k - \alpha(Ax_k - b).$$

А точное решение удовлетворяет

$$Ax^* = b.$$

Главный вопрос следующей лекции

При каких значениях шага α последовательность x_k действительно приходит к x^* ? И как скорость зависит от $\lambda_{\min}$, $\lambda_{\max}$ и $\kappa(A)$?

Именно здесь обусловленность начнёт непосредственно управлять поведением алгоритма.