



Совместная программа СМОЛ ГУ и
ФКН НИУ ВШЭ

2026/27 учебный год

Методы оптимизации в машинном обучении

Лекция 5. Выпуклость и условия оптимальности

Никита Лукьяненко



Что мы уже умеем



На прошлой лекции мы научились доказывать, что при подходящем шаге градиентный спуск уменьшает функцию:

$$f(x_{k+1}) < f(x_k).$$

Но остаётся более фундаментальный вопрос:

К какому минимуму мы вообще можем прийти?

Убывание функции само по себе не говорит, в какой минимум мы придём





Проблема локального минимума

Для невыпуклой функции возможны разные стационарные точки:

- локальные минимумы разного качества;
- локальные максимумы;
- седловые точки.

Главный вопрос

Можно ли выделить класс функций, для которых **любой локальный минимум автоматически глобален?**

Ответ этой лекции: да. Такой класс задаёт **выпуклость**.



Почему выпуклость так полезна

выпуклость $\implies$ простая геометрия $\implies$ простые условия оптимальности $\implies$ глобальные гарантии

Сегодня мы свяжем три уже знакомых объекта:

геометрию функции $\nabla f(x)$ $\nabla^2 f(x)$.

И увидим, как они позволяют распознавать глобальный минимум.



Отрезок между двумя точками

Пусть $x, y \in \mathbb{R}^d$. Точки отрезка между ними имеют вид

$$z(t) = (1 - t)x + ty, \quad t \in [0, 1].$$

При $t = 0$ получаем x , при $t = 1$ — y .

Идея

Выпуклое множество устроено так, что вместе с любыми двумя своими точками содержит и весь соединяющий их отрезок.



Определение выпуклого множества

Определение

Множество $X \subseteq \mathbb{R}^d$ называется **выпуклым**, если для любых $x, y \in X$ и любого $t \in [0, 1]$


$$(1 - t)x + ty \in X.$$

Это определение требует проверки **для любой пары точек** множества.



Как выглядит выпуклость геометрически


Шар — выпуклый




Прямоугольник — выпуклый



Полуплоскость — выпуклая



Невыпуклое множество



В невыпуклом множестве хотя бы один отрезок между двумя допустимыми точками выходит наружу.



Самопроверка: какие множества выпуклы?

Определите, какие из множеств выпуклы:

$$X_1 = \{x : \|x\|_2 \leq 1\},$$

$$X_2 = \{x \in \mathbb{R}^2 : x_1 + x_2 \leq 1\},$$

$$X_3 = \{x : \|x\|_2 = 1\},$$

$$X_4 = \{x \in \mathbb{R}^2 : x_1 x_2 \geq 1\}.$$

Совет

Чтобы показать невыпуклость, достаточно найти **одну** пару точек, для которой отрезок выходит из множества.



Выпуклая комбинация

Пусть $x_1, \dots, x_m \in \mathbb{R}^d$, а коэффициенты удовлетворяют


$$\alpha_i \geq 0, \quad \sum_{i=1}^m \alpha_i = 1.$$

Тогда

$$\sum_{i=1}^m \alpha_i x_i$$

называется **выпуклой комбинацией** точек x_i .

Выпуклая комбинация остаётся внутри выпуклого множества





Выпуклое множество содержит выпуклые комбинации

Утверждение

Если X выпукло и $x_1, \dots, x_m \in X$, то при

$$\alpha_i \geq 0, \quad \sum_i \alpha_i = 1$$

имеем

$$\sum_i \alpha_i x_i \in X.$$

Для двух точек это равно определение. Для трёх точек можно сначала объединить x_1, x_2 , а затем полученную точку — с x_3 .



Почему область определения тоже должна быть выпуклой

Дальше мы будем сравнивать значения функции в точках

$$(1 - t)x + ty.$$

Если эта точка выходит из области определения, само сравнение теряет смысл.

Поэтому

Говоря о выпуклой функции $f : X \rightarrow \mathbb{R}$, обычно предполагают, что её область X сама выпукла.



Геометрическая идея выпуклой функции

Хордовое определение: график выпуклой функции лежит не выше хорды





График выпуклой функции лежит **не выше** любой хорды, соединяющей две точки её графика.



Определение выпуклой функции

Определение

Функция $f : X \rightarrow \mathbb{R}$ на выпуклом множестве X называется **выпуклой**, если для любых $x, y \in X$ и $t \in [0, 1]$

$$f((1-t)x + ty) \leq (1-t)f(x) + tf(y).$$



Как читать определение буквально

Слева:

$$f\left(\underbrace{(1-t)x + ty}\right).$$

выпуклая комбинация аргументов

Справа:

$$\underbrace{(1-t)f(x) + tf(y)}.$$

та же комбинация значений функции

Смысл

Сначала усреднить аргументы и затем вычислить функцию — не хуже, чем сначала вычислить значения, а потом усреднить их.



Пример: $f(x) = x^2$ выпукла


Нужно проверить

$$((1-t)x + ty)^2 \leq (1-t)x^2 + ty^2.$$

Рассмотрим разность правой и левой частей:

$$\begin{aligned} (1-t)x^2 + ty^2 - ((1-t)x + ty)^2 \\ = t(1-t)(x-y)^2 \geq 0. \end{aligned}$$

Следовательно, условие выпуклости выполняется.





Невыпуклый пример

Функция

$$f(x) = x^3$$

на всей $\mathbb{R}$ не является выпуклой.

Например, её кривизна меняет знак: слева от нуля

$$f''(x) = 6x < 0,$$

а справа

$$f''(x) > 0.$$

Позже мы увидим, что это уже достаточная причина невыпуклости на всей прямой.



Линейная функция — пограничный случай

Пусть

$$f(x) = a^\top x + b.$$

Тогда

$$\begin{aligned} f((1-t)x + ty) &= a^\top ((1-t)x + ty) + b \\ &= (1-t)f(x) + tf(y). \end{aligned}$$

То есть в определении выпуклости всегда выполняется **равенство**.

Следствие

Линейная функция одновременно выпукла и вогнута.



Неравенство Йенсена

Для выпуклой функции и выпуклой комбинации

$$\alpha_i \geq 0, \quad \sum_i \alpha_i = 1$$

справедливо

$$f\left(\sum_i \alpha_i x_i\right) \leq \sum_i \alpha_i f(x_i).$$

Это называется **неравенством Йенсена**.



Йенсен — это обобщение определения

При $m = 2$

$$\alpha_1 = 1 - t, \quad \alpha_2 = t,$$

и неравенство Йенсена превращается в

$$f((1 - t)x + ty) \leq (1 - t)f(x) + tf(y).$$

Для большего числа точек результат получается последовательным применением определения.



Мини-задача на Йенсена

Функция $f(x) = e^x$ выпукла. Примените Йенсена к двум точкам с одинаковыми весами:

$$\alpha_1 = \alpha_2 = \frac{1}{2}.$$

Получаем

$$e^{(x+y)/2} \leq \frac{e^x + e^y}{2}.$$

Это простейший пример того, как выпуклость автоматически порождает полезные неравенства.



Но определение неудобно проверять напрямую

Чтобы проверить выпуклость по определению, формально нужно убедиться в неравенстве

$$f((1 - t)x + ty) \leq (1 - t)f(x) + tf(y)$$


для **всех** x, y и **всех** $t \in [0, 1]$.

Нужны локальные критерии

Если функция дифференцируема, можно описать выпуклость через градиент. Если дважды дифференцируема — через гессиан.



Касательная к выпуклой функции



В отличие от обычной локальной аппроксимации, у выпуклой функции касательная оказывается **глобальной нижней оценкой**.



Критерий первого порядка

Теорема

Пусть f дифференцируема на выпуклом множестве X . Тогда

$$f \text{ выпукла} \iff f(y) \geq f(x) + \nabla f(x)^\top (y - x)$$

для любых $x, y \in X$.

Правая часть — касательная гиперплоскость к графику в точке x .



Связь с локальной моделью из лекции 2

Раньше мы писали

$$f(x + h) \approx f(x) + \nabla f(x)^\top h.$$

Это была **локальная** линейная модель.

Для выпуклой функции при $h = y - x$ получаем уже точное глобальное утверждение:

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x).$$

Главная мысль

Линейная модель выпуклой функции никогда не переоценивает саму функцию.



Доказательство критерия: направление $\Rightarrow$

Предположим, что f выпукла. Зафиксируем x, y и определим функцию одной переменной

$$\varphi(t) = f(x + t(y - x)), \quad t \in [0, 1].$$

По выпуклости

$$\varphi(t) \leq (1 - t)\varphi(0) + t\varphi(1).$$

Переносим $\varphi(0)$ и делим на $t > 0$:

$$\frac{\varphi(t) - \varphi(0)}{t} \leq \varphi(1) - \varphi(0).$$



Доказательство критерия: предел при $t \rightarrow 0+$

Переходим к пределу:

$$\varphi'(0) \leq f(y) - f(x).$$

Но по правилу цепочки

$$\varphi'(0) = \nabla f(x)^\top (y - x).$$

Следовательно,

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x).$$



Обратное направление критерия

Теперь предположим, что для любых u, v

$$f(v) \geq f(u) + \nabla f(u)^\top (v - u).$$

Положим

$$z = (1 - t)x + ty.$$

Применим условие в точке z отдельно к x и y :

$$f(x) \geq f(z) + \nabla f(z)^\top (x - z),$$

$$f(y) \geq f(z) + \nabla f(z)^\top (y - z).$$



Завершение обратного направления

Умножим первое неравенство на $1 - t$, второе на t и сложим:

$$(1 - t)f(x) + tf(y) \geq f(z) \\ + \nabla f(z)^T ((1 - t)(x - z) + t(y - z)).$$

Но

$$(1 - t)(x - z) + t(y - z) = 0.$$

Поэтому

$$f((1 - t)x + ty) \leq (1 - t)f(x) + tf(y).$$

Это и есть выпуклость.



Что стоит запомнить из критерия первого порядка

Не обязательно начинать с формулы. Геометрически утверждение звучит так:

касательная к выпуклой функции — глобальная нижняя оценка.

Это позволяет превращать локальную информацию $\nabla f(x)$ в утверждение о функции во всём пространстве.

Для коллоквиума

Важно уметь и сформулировать критерий, и восстановить доказательство через функцию $\varphi(t) = f(x + t(y - x))$.



Самопроверка: квадратичная функция

Пусть

$$f(x) = \frac{1}{2}x^{\top}Ax, \quad A = A^{\top}.$$

Критерий первого порядка требует

$$\frac{1}{2}y^{\top}Ay \geq \frac{1}{2}x^{\top}Ax + x^{\top}A(y - x).$$

После упрощения:

$$\frac{1}{2}(y - x)^{\top}A(y - x) \geq 0.$$


Какое условие на A обеспечивает это для любых x, y ?



Локальный минимум выпуклой функции – глобальный

Теорема

Пусть f выпукла на выпуклом множестве X . Тогда любой локальный минимум x^* функции f является глобальным.





Доказательство: предположим обратное

Пусть x^* — локальный минимум, но существует $y \in X$ такое, что

$$f(y) < f(x^*).$$

Рассмотрим точки

$$x_t = (1 - t)x^* + ty, \quad t \in (0, 1).$$

При малом $t > 0$ точка x_t находится сколь угодно близко к x^* .



Доказательство: противоречие с локальностью

По выпуклости

$$\begin{aligned} f(x_t) &\leq (1-t)f(x^*) + tf(y) \\ &< (1-t)f(x^*) + tf(x^*) \\ &= f(x^*). \end{aligned}$$

Но x_t можно выбрать сколь угодно близко к x^* . Это противоречит тому, что x^* — локальный минимум.



Условие оптимальности для дифференцируемой выпуклой функции

Теорема

Если f дифференцируема и выпукла на $\mathbb{R}^d$, то

$$\nabla f(x^*) = 0 \iff x^* \text{ — глобальный минимум } f.$$

Левая часть — локальное условие. Выпуклость превращает его в глобальный результат.



Почему $\nabla f(x^*) = 0$ достаточно

Из критерия первого порядка для любого y :

$$f(y) \geq f(x^*) + \nabla f(x^*)^\top (y - x^*).$$

Если

$$\nabla f(x^*) = 0,$$

то

$$f(y) \geq f(x^*) \quad \forall y.$$

Следовательно, x^* — глобальный минимум.



Почему это фундаментально

Для произвольной гладкой функции условие

$$\nabla f(x) = 0$$

может означать:

минимум, максимум, седловую точку.

Для дифференцируемой выпуклой функции:

$$\nabla f(x) = 0 \implies \text{глобальный минимум.}$$

Это одна из главных причин, почему выпуклые задачи настолько удобны.



Можно ли распознать выпуклость через гессиан?


На лекции 2 мы получили формулу направленной кривизны:

$$\left. \frac{d^2}{dt^2} f(x + tv) \right|_{t=0} = v^T \nabla^2 f(x) v.$$


Если функция выпукла, вдоль любой прямой она должна изгибаться **вверх**, а не вниз.

Знак направленной кривизны определяется гессианом


$H > 0$



$H \geq 0$, есть плоское направление



Неопределённый H





Критерий второго порядка

Теорема

Пусть f дважды непрерывно дифференцируема на выпуклом открытом множестве. Тогда

$$f \text{ выпукла} \iff \nabla^2 f(x) \succeq 0 \quad \forall x.$$

То есть выпуклость эквивалентна неотрицательной кривизне во всех направлениях и во всех точках.



Почему выпуклость даёт $\nabla^2 f \succeq 0$

Зафиксируем точку x и направление v . Рассмотрим одномерное сечение

$$\varphi(t) = f(x + tv).$$

Если f выпукла, то φ тоже выпукла как функция одной переменной. Поэтому

$$\varphi''(t) \geq 0.$$

Но

$$\varphi''(t) = v^\top \nabla^2 f(x + tv) v.$$

Значит, для любого v

$$v^\top \nabla^2 f(x) v \geq 0,$$

то есть $\nabla^2 f(x) \succeq 0$.



Обратное направление критерия второго порядка

Пусть теперь

$$\nabla^2 f(x) \succeq 0 \quad \forall x.$$

Для любых x, y рассмотрим

$$\varphi(t) = f(x + t(y - x)).$$

Тогда

$$\varphi''(t) = (y - x)^\top \nabla^2 f(x + t(y - x))(y - x) \geq 0.$$

Следовательно, φ выпукла на $[0, 1]$, а значит

$$\varphi(t) \leq (1 - t)\varphi(0) + t\varphi(1).$$

Это ровно выпуклость f .



Квадратичная функция как частный случай

Для

$$f(x) = \frac{1}{2}x^{\top}Ax - b^{\top}x + c, \quad A = A^{\top},$$

мы знаем

$$\nabla^2 f(x) = A.$$

Поэтому

$$f \text{ выпукла} \iff A \succeq 0.$$

Это полностью согласуется со спектральной геометрией лекции 3.



Практический алгоритм проверки выпуклости

Если функция дважды дифференцируема:

$$f \longrightarrow H(x) = \nabla^2 f(x) \longrightarrow \text{проверить } H(x) \succeq 0 \text{ для всех } x.$$

Но есть нюанс

Если гессиан зависит от x , проверка положительной полуопределённости **во всех точках** может быть сама по себе нетривиальной задачей.



Выпуклость не гарантирует единственность минимума

Рассмотрим

$$f(x, y) = x^2.$$

Функция выпукла, но

$$f(0, y) = 0$$

для любого y .

То есть глобальных минимумов бесконечно много:

$$\arg \min f = \{(0, y) : y \in \mathbb{R}\}.$$

Нужное усиление называется **строгой выпуклостью**.



Строгая выпуклость

Определение

Функция f называется **строго выпуклой**, если для любых $x \neq y$ и $t \in (0, 1)$

$$f((1 - t)x + ty) < (1 - t)f(x) + tf(y).$$

В отличие от обычной выпуклости, хорда теперь лежит **строго выше** графика между различными точками.



Строгая выпуклость даёт единственность

Теорема

Строго выпуклая функция имеет не более одного глобального минимума.

Предположим, что $x \neq y$ — два минимума и

$$f(x) = f(y) = f^*.$$

Тогда по строгой выпуклости

$$f\left(\frac{x+y}{2}\right) < \frac{1}{2}f(x) + \frac{1}{2}f(y) = f^*,$$

противоречие.



Но строгая выпуклость не контролирует силу кривизны



Функция x^4 строго выпукла, но около нуля её вторая производная стремится к нулю. Значит, одной строгой выпуклости недостаточно для количественных оценок скорости.



Сильная выпуклость

Определение


Дифференцируемая функция f называется μ -**сильно выпуклой**, если существует $\mu > 0$ такое, что для любых x, y

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2} \|y - x\|^2.$$

По сравнению с обычной выпуклостью появляется дополнительный положительный квадратичный запас.



Геометрия сильной выпуклости



Функция лежит выше не просто касательной, а **параболической опоры** с кривизной μ .



Критерий сильной выпуклости через гессиан

Для дважды дифференцируемой функции

$$f \text{ } \mu\text{-сильно выпукла} \iff \nabla^2 f(x) \succeq \mu I \quad \forall x.$$

Удобный способ увидеть это: функция

$$g(x) = f(x) - \frac{\mu}{2} \|x\|^2$$

выпукла тогда и только тогда, когда

$$\nabla^2 g(x) = \nabla^2 f(x) - \mu I \succeq 0.$$



Связь с гладкостью и числом обусловленности

Если одновременно

$$\mu I \preceq \nabla^2 f(x) \preceq LI \quad \forall x,$$

то кривизна функции во всех направлениях находится между μ и L .

Естественно определить

$$\kappa = \frac{L}{\mu}.$$

Связь с лекциями 3–4

Для квадратичной функции это равно

$$\kappa(A) = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}.$$



Пример из ML: метод наименьших квадратов

Рассмотрим уже знакомую задачу

$$f(w) = \frac{1}{2} \|Xw - y\|^2.$$

Её гессиан

$$\nabla^2 f(w) = X^\top X.$$

Для любого z

$$z^\top X^\top X z = \|Xz\|^2 \geq 0.$$

Следовательно,

$$X^\top X \succeq 0,$$

и задача выпукла.



Когда минимум линейной регрессии единственный?

Если столбцы X линейно независимы, то

$$Xz \neq 0 \quad \forall z \neq 0.$$

Поэтому

$$z^T X^T X z = \|Xz\|^2 > 0,$$

то есть

$$X^T X \succ 0.$$

Следовательно, функция строго и сильно выпукла, а минимум единственен.



Ridge добавляет кривизну

Для Ridge-регрессии


$$f(w) = \frac{1}{2} \|Xw - y\|^2 + \frac{\lambda}{2} \|w\|^2, \quad \lambda > 0,$$

имеем


$$\nabla^2 f = X^\top X + \lambda I \succeq \lambda I.$$

Ridge добавляет кривизну во всех направлениях

Без регуляризации
 $\lambda_{\min} = 0.12$, $\kappa = 20.8$



Ridge: $A + \lambda I$
 $\lambda_{\min} = 0.77$, $\kappa = 4.1$





Логистическая потеря тоже выпукла



Для одного объекта удобно рассматривать

$$\ell(z) = \log(1 + e^{-z}).$$

Её вторая производная

$$\ell''(z) = \frac{e^z}{(1 + e^z)^2} > 0.$$

Следовательно, ℓ строго выпукла по z .





Сумма выпуклых функций остаётся выпуклой

Утверждение

Если f_i выпуклы и $\alpha_i \geq 0$, то

$$F(x) = \sum_i \alpha_i f_i(x)$$

выпукла.

Действительно,

$$\begin{aligned} F((1-t)x + ty) &= \sum_i \alpha_i f_i((1-t)x + ty) \\ &\leq \sum_i \alpha_i ((1-t)f_i(x) + tf_i(y)) \\ &= (1-t)F(x) + tF(y). \end{aligned}$$


Отсюда средний эмпирический риск из выпуклых потерь тоже выпуклый.



Где эта теория перестаёт работать

Для параметров глубокой нейронной сети функция потерь обычно невыпукла.

Невыпуклая задача: стационарные точки уже не равнозначны



Поэтому уже нельзя автоматически утверждать:

локальный минимум = глобальный,

$\nabla f(x) = 0 \implies$ глобальный минимум.



Итоги и следующий вопрос

Сегодня мы получили цепочку

$$\text{выпуклость} \implies f(y) \geq f(x) + \nabla f(x)^\top (y - x) \implies \nabla f(x^*) = 0 \iff x^* - \text{глобальный минимум}$$

и критерий

$$f \text{ выпукла} \iff \nabla^2 f(x) \succeq 0.$$

Для сильно выпуклой и гладкой функции

$$\mu I \preceq \nabla^2 f(x) \preceq LI, \quad \kappa = \frac{L}{\mu}.$$

Следующая лекция

Теперь мы знаем, **куда** должен прийти градиентный спуск. Следующий вопрос: **насколько быстро он туда приходит?**